

Universidad Andrés Bello
Facultad de Ingeniería

**Plataforma de Predicción de Demanda y Reabastecimiento Automático
para Distribuidoras**
Informe de Tesis - Versión Extendida (Fase 1 y 2)

Proyecto de Tesis UNAB

Mayo 2026

Índice general

1. Planteamiento del problema	2
1.0.1. Contexto de la Industria	2
1.0.2. Descripción del Problema Central	2
1.0.3. Consecuencias e Impacto Económico	2
1.0.4. Brecha Tecnológica y Operativa	3
1.0.5. Pregunta de Investigación y Objetivo de Mejora	3
2. Metodología de Procesamiento de Datos (Fase 2)	4
2.0.1. Marco de Trabajo: CRISP-DM	4
2.0.2. Infraestructura de Big Data	4
2.0.3. Ingeniería de Características (<i>Feature Engineering</i>)	4
2.0.4. Validación de Datos	5
3. Arquitectura del Sistema	6
3.0.1. Capa de Ingesta y Procesamiento (<i>Big Data</i>)	6
3.0.2. Capa Analítica: Motor de <i>Forecasting</i> Híbrido	6
3.0.3. Motor de Optimización de Inventario	6
3.0.4. Interfaz y Consumo (<i>Full-Stack</i>)	7
4. Métricas de Evaluación	8
4.0.1. Métricas de Rendimiento del Modelo (<i>Forecasting</i>)	8
4.0.2. Métricas de Gestión de Inventario (KPIs de Negocio)	8

Capítulo 1

Planteamiento del problema

1.0.1. Contexto de la Industria

En el escenario actual de la cadena de suministro en Chile, las pequeñas y medianas empresas (PYMEs) distribuidoras enfrentan una presión creciente por optimizar sus costos operativos debido a la volatilidad del mercado y la digitalización de la competencia. Actualmente, la gestión de inventarios y la planificación de la demanda en estas organizaciones se caracteriza por una baja madurez tecnológica, donde las decisiones de compra se basan mayoritariamente en la intuición de los encargados (*“feeling”*), experiencias pasadas no sistematizadas o el uso de planillas de cálculo estáticas (Excel).

1.0.2. Descripción del Problema Central

El núcleo del problema radica en la gestión reactiva del inventario. Las distribuidoras suelen reaccionar ante la falta de stock en lugar de anticiparse a la demanda futura. Esta falta de una gestión predictiva se debe a la carencia de herramientas que puedan procesar grandes volúmenes de datos (*Big Data*) y aplicar modelos analíticos específicos para cada tipo de producto o SKU.

Al aplicar modelos de pronóstico homogéneos o simplistas para todo el catálogo, las empresas ignoran factores críticos como:

- **Estacionalidad y Tendencias:** No se capturan adecuadamente los ciclos de venta mensuales o anuales.
- **Volatilidad de la Demanda:** Productos con demanda intermitente son tratados igual que productos de alta rotación, generando errores de cálculo.
- **Variables Externas:** La omisión de factores como promociones, feriados locales o eventos climáticos degrada la precisión de las compras.

1.0.3. Consecuencias e Impacto Económico

Esta deficiencia en la planificación de la demanda deriva en dos escenarios financieros adversos y costosos:

1. **Exceso de Stock (Sobrestock):** Genera una acumulación de productos de baja rotación, lo que se traduce en capital inmovilizado que no genera retorno y aumenta los costos de almacenamiento y riesgo de merma o vencimiento.
2. **Quiebres de Inventario (Stockouts):** Cuando la demanda supera las existencias no previstas, se producen pérdidas de ventas directas, deterioro de la relación con el cliente y pérdida de participación de mercado frente a competidores con mejor disponibilidad.

1.0.4. Brecha Tecnológica y Operativa

Existe una incapacidad técnica para integrar las restricciones reales de la cadena de suministro en el proceso de pedido. Los sistemas actuales no suelen considerar de forma dinámica:

- **Lead Times (Tiempos de entrega):** La variabilidad en los tiempos de respuesta de los proveedores.
- **Restricciones de Compra:** Mínimos de pedido (MOQ), tamaños de empaque (*pack size*) y capacidades logísticas.

1.0.5. Pregunta de Investigación y Objetivo de Mejora

¿En qué medida la implementación de una plataforma que automatice la selección del modelo de forecasting (ARIMA, Prophet, XGBoost, LSTM) por cada SKU, integrada con un motor de optimización de inventario (EOQ y políticas $\langle s, S \rangle$ dinámicas), logra reducir el error de predicción y minimizar el capital inmovilizado? El éxito se define por alcanzar un Nivel de Servicio igual o superior al 95 % mientras se optimiza la eficiencia financiera del inventario.

Capítulo 2

Metodología de Procesamiento de Datos (Fase 2)

Esta fase se centra en la transformación de datos en bruto provenientes de diversas fuentes en un dataset optimizado para el entrenamiento de modelos de Machine Learning y Deep Learning.

2.0.1. Marco de Trabajo: CRISP-DM

El proyecto sigue la metodología CRISP-DM (*Cross-Industry Standard Process for Data Mining*), habiendo completado en esta etapa los hitos de Entendimiento de Datos y Preparación de Datos:

- **Comprensión de los Datos:** Análisis exploratorio de más de 3 millones de registros para identificar patrones de estacionalidad y calidad de la información.
- **Preparación de los Datos:** Selección, limpieza y transformación de variables críticas para el pronóstico.

2.0.2. Infraestructura de Big Data

Debido al volumen masivo de información (dataset de Corporación Favorita y proyecciones para PYMEs con miles de SKUs), se ha definido la siguiente arquitectura técnica:

- **Apache Spark:** Utilizado como motor de procesamiento distribuido para manejar la carga de datos sin cuellos de botella en memoria.
- **Hadoop (HDFS):** Empleado para el almacenamiento escalable de los archivos de entrenamiento y validación.
- **Google Cloud Platform (GCP):** Entorno de nube para la ejecución de los *jobs* de procesamiento y el despliegue de los contenedores de modelos.

2.0.3. Ingeniería de Características (*Feature Engineering*)

Para mejorar la capacidad predictiva de los modelos (especialmente XGBoost y LSTM), se aplican las siguientes transformaciones mediante Spark MLlib:

- **Tratamiento de Datos Faltantes:** Implementación de imputación automática para días sin ventas, diferenciando entre cierres de tienda y demanda cero.
- **Codificación de Variables Categóricas:**

- **StringIndexer:** Para convertir etiquetas de texto (familias de productos, ciudades) en índices numéricos.
- **OneHotEncoder:** Para evitar que el modelo asuma una jerarquía inexistente en las categorías de productos.
- **Extracción de Características Temporales:** Descomposición de la fecha en componentes de día de la semana, mes, año y bandera de feriados (crucial para el modelo Prophet).
- **Normalización y Escalado:** Uso de `StandardScaler` para asegurar que variables con diferentes unidades (precios unitarios vs. cantidades totales) tengan el mismo peso relativo en el entrenamiento.

2.0.4. Validación de Datos

- **Análisis de Outliers:** Identificación de picos de venta anómalos mediante métodos estadísticos para evitar que promociones puntuales sesguen el pronóstico base.
- **División del Dataset:** Separación de datos en entrenamiento (*train*), validación y prueba (*test*) respetando la cronología temporal para evitar el *data leakage*.

Capítulo 3

Arquitectura del Sistema

La arquitectura está diseñada bajo un enfoque de microservicios y procesamiento distribuido, permitiendo que la plataforma escale según el volumen de transacciones y SKUs de la empresa.

3.0.1. Capa de Ingesta y Procesamiento (*Big Data*)

El núcleo técnico se apoya en el ecosistema Hadoop para garantizar la integridad y velocidad del procesamiento:

- **Almacenamiento:** Se utiliza HDFS para centralizar datos históricos de ventas, inventarios y catálogos de proveedores.
- **Procesamiento en *Batch*:** Apache Spark ejecuta procesos ETL para limpiar y transformar los datos en tiempo real o por lotes, preparando los tensores para los modelos de aprendizaje profundo.

3.0.2. Capa Analítica: Motor de *Forecasting* Híbrido

A diferencia de sistemas tradicionales, esta arquitectura implementa un Selector Inteligente de Modelos. El sistema evalúa cada SKU y aplica el algoritmo que mejor se adapte a su comportamiento histórico:

1. **Prophet (Meta):** Especializado en capturar estacionalidades complejas (anuales, semanales) y efectos de feriados o eventos especiales.
2. **XGBoost:** Un modelo de ensamble basado en árboles de decisión, ideal para detectar patrones no lineales y relaciones entre múltiples variables externas.
3. **LSTM (*Long Short-Term Memory*):** Una red neuronal recurrente diseñada para secuencias temporales largas, capaz de recordar dependencias de datos pasados para predecir tendencias futuras.
4. **ARIMA/SARIMA:** Modelos estadísticos clásicos utilizados como base (*baseline*) para productos con demanda altamente estable y lineal.

3.0.3. Motor de Optimización de Inventario

Una vez generado el pronóstico, los resultados pasan a un motor lógico que traduce “unidades de venta estimadas” en “órdenes de compra”:

- **Modelo EOQ (*Economic Order Quantity*):** Calcula la cantidad óptima de pedido para minimizar el costo total de mantenimiento y pedido.

- **Cálculo de Stock de Seguridad:** Determina el colchón de inventario necesario basándose en el error del modelo de pronóstico y la variabilidad del *Lead Time* del proveedor.
- **Política de Revisión $\langle s, S \rangle$:** Define el punto de reorden (s) y el nivel máximo de inventario (S) para automatizar la reposición.

3.0.4. Interfaz y Consumo (*Full-Stack*)

La salida de los modelos se disponibiliza a través de una arquitectura moderna para asegurar una experiencia de usuario fluida:

- **Backend:** Desarrollado en **FastAPI**, proporcionando una comunicación eficiente y rápida entre el motor de Python (IA) y la interfaz.
- **Frontend:** Construido en **React**, permitiendo a los gerentes de operaciones visualizar *dashboards* interactivos y alertas de quiebre de *stock*.
- **Base de Datos:** **PostgreSQL** para la persistencia de configuraciones de usuario y resultados finales de las recomendaciones de compra.

Capítulo 4

Métricas de Evaluación

4.0.1. Métricas de Rendimiento del Modelo (*Forecasting*)

Estas métricas permiten comparar los algoritmos (Prophet, XGBoost, LSTM, ARIMA) para seleccionar el más exacto por cada SKU:

- **RMSE (*Root Mean Squared Error*):** Se utiliza para penalizar los errores grandes, lo cual es crítico en productos de alta rotación donde una desviación importante puede causar desabastecimiento masivo.
- **MAE (*Mean Absolute Error*):** Proporciona una medida del error promedio en unidades físicas, facilitando la comprensión del error en términos de volumen de productos.
- **WAPE (*Weighted Average Percentage Error*):** Es la métrica principal para el negocio, ya que pondera el error según el volumen de ventas, evitando que productos de baja rotación distorsionen la percepción de precisión global.

4.0.2. Métricas de Gestión de Inventario (KPIs de Negocio)

Estas métricas validan si la arquitectura del sistema cumple con los objetivos financieros y operativos planteados:

- **Nivel de Servicio (*Service Level*):** El objetivo principal es alcanzar o superar el 95 %, midiendo el porcentaje de pedidos de clientes que se satisfacen inmediatamente con el *stock* disponible.
- **Tasa de Quiebre de Stock (*Stockout Rate*):** Mide la frecuencia con la que un SKU llega a cero, permitiendo evaluar la eficacia del Stock de Seguridad calculado por el sistema.
- **Días de Inventario (*Days on Hand*):** Evalúa la eficiencia del capital inmovilizado; el sistema busca reducir este indicador asegurando que el *stock* rote más rápido sin afectar el nivel de servicio.
- **Precisión de la Orden de Compra:** Comparación entre la sugerencia del modelo (EOQ) y la demanda real observada durante el *Lead Time* del proveedor.

Bibliografía

- [1] Apache Software Foundation. Apache Spark: Unified Engine for Big Data Processing.
- [2] Revista Logistec (2023). Quiebres y sobrestock en Chile.
- [3] Vilchez et al. (2024). Optimización de inventarios en PYMEs retail.